M2 | MA PRÉSENTATION

Comment j’ai analysé Compar:IA

Un résumé simple des cinq questions, de ma démarche et de ce que j’ai trouvé.

410 016	350 270	3
conversations dans le fichier	avec les deux estimations d’énergie	fichiers reliés par conversation

Avant de présenter les résultats

J’ai comparé les deux réponses données à une même demande quand c’était possible. Les valeurs en kWh sont des estimations fournies dans les fichiers : elles ne viennent pas d’une mesure directe au compteur. Une « médiane » est la valeur du milieu quand on range les résultats du plus petit au plus grand.

1re partie | modèles, sujets et longueur

1. Quels modèles ont l’estimation la plus faible pour une même demande ?

Comment j’ai fait : Pour chaque demande à laquelle deux modèles ont répondu, j’ai comparé leurs estimations d’énergie. J’ai ensuite compté la part des comparaisons où chaque modèle avait la valeur la plus basse. Pour garder assez de données, j’ai classé seulement les modèles avec au moins 1 000 réponses comparées.

Ce que j’ai trouvé : chocolatine-2-14b-instruct-v2.0.3-q8 a la valeur la plus basse dans 98,0 % de ses 2 696 comparaisons. gpt-5.4-nano la suit avec 96,4 % sur 2 314 comparaisons, puis lfm2-8b-a1b avec 96,0 % sur 4 370. Si je compare des réponses de même longueur, lfm2-8b-a1b a la plus faible estimation : 0,081 Wh pour 1 000 unités de texte généré.

Comment je le comprends : Le modèle qui gagne le plus souvent sur l’énergie totale n’a pas forcément la plus faible estimation pour une même quantité de texte. Une réponse plus courte peut demander moins d’énergie au total.

2. L’énergie estimée change-t-elle selon le sujet ou la longueur de la demande ?

Comment j’ai fait : J’ai compté les mots de la demande et formé cinq groupes. J’ai comparé l’énergie au milieu de chaque groupe, ainsi que la longueur des réponses. J’ai aussi comparé les grands sujets indiqués dans les données, comme l’éducation ou la santé.

Ce que j’ai trouvé : Pour les demandes de 1 à 10 mots, l’énergie médiane est de 0,000260 kWh par réponse. Pour celles de plus de 200 mots, elle atteint 0,001174 kWh. Les réponses correspondantes sont aussi plus longues : 552 unités de texte au milieu du groupe court, contre 1 204 pour le groupe long. Selon le sujet, les estimations totales changent, mais elles sont très proches quand on les ramène à une même longueur de réponse.

Comment je le comprends : Les demandes longues entraînent souvent des réponses longues. Les sujets se mélangent parfois dans une même demande, et les modèles ne sont pas répartis pareil selon les sujets. Je ne peux donc pas dire que le sujet, à lui seul, explique l’écart.

2e partie | votes et réactions

3. Les utilisateurs choisissent-ils plus souvent le modèle à l'estimation la plus basse ?

Comment j'ai fait : J'ai relié les votes aux conversations correspondantes. J'ai retiré les votes qui indiquaient une égalité ou qui ne précisaient pas de modèle préféré, puis j'ai regardé lequel des deux modèles avait l'estimation la plus basse.

Ce que j'ai trouvé : Sur 83 842 votes clairs, le modèle choisi avait l'estimation la plus basse dans 42,89 % des cas. Dans 57,11 % des cas, il avait l'estimation la plus élevée. Il y a aussi 132 cas où les estimations étaient égales et 25 votes impossibles à relier à l'un des deux modèles.

Comment je le comprends : Dans cet échantillon, les utilisateurs ne choisissent pas plus souvent le modèle à l'estimation la plus faible. Cela décrit seulement les personnes qui ont voté.

4. Les réponses appréciées pour leur qualité ont-elles une estimation plus élevée ?

Comment j'ai fait : Pour chaque demande, j'ai comparé les deux réponses lorsque les utilisateurs avaient donné des appréciations différentes, par exemple « utile » pour l'une mais pas pour l'autre.

Ce que j'ai trouvé : La réponse jugée utile, complète, créative ou claire avait une estimation totale plus élevée dans environ 55 %, 61 %, 58 % et 57 % des comparaisons. À l'inverse, la réponse signalée comme incorrecte, superficielle ou ne suivant pas les consignes avait plus souvent une estimation plus faible.

Comment je le comprends : Cela ne veut pas dire qu'une bonne réponse consomme forcément plus d'énergie. Les avis sont subjectifs, et la longueur des réponses ou le modèle utilisé peuvent aussi jouer.

5. Les réponses aimées ont-elles une estimation différente des réponses détestées ?

Comment j'ai fait : J'ai relié chaque réaction au modèle qu'elle visait et comparé uniquement les réactions clairement marquées « aimée » ou « détestée ». J'ai regardé l'estimation totale et l'estimation pour une même quantité de texte.

Ce que j'ai trouvé : J'ai pu utiliser 57 107 réactions aimées et 25 904 détestées. L'estimation médiane totale est de 0,000809 kWh pour les réponses aimées, contre 0,000286 pour les réponses détestées. Les réponses aimées sont aussi plus longues : 908 unités de texte au milieu du groupe, contre 682. À longueur comparable, l'écart est plus faible.

Comment je le comprends : Je ne peux pas dire que le fait d'aimer une réponse augmente son énergie. Les réponses aimées sont plus longues et peuvent venir de modèles différents.

Ce que je retiens	Dans les données que j'ai étudiées, les estimations varient selon le modèle et augmentent surtout quand les réponses sont plus longues. Les votes ne montrent pas que les utilisateurs préfèrent le modèle à l'estimation la plus basse. Ce sont des estimations et des tendances observées, pas des mesures électriques réelles ni des preuves de cause à effet.

Source : les trois fichiers Parquet du dossier compareAI. Les scripts et le détail des calculs sont dans analyse_comparia.ipynb.