Documentation de la V0.2 d’éco-routage

Fonctionnement, formules, résultats et interprétation

Projet de M2 | Version documentée le 5 novembre 2026

Conclusion principale

La V0.2 teste deux façons de tenir compte séparément de la longueur d’entrée et de sortie. Sur le test CompareAI actuel, elle reproduit la référence aussi bien que la V0.1, sans gain mesuré. Cela ne permet pas de conclure que les tokens d’entrée ne consomment pas d’énergie réelle. Les résultats SweetSpot/H100 apportent un signal complémentaire, limité à cette configuration.

Ce document explique ce que calcule le prototype, comment lire ses métriques et quelles conclusions sont raisonnables. Il s’adresse aux membres du projet qui doivent comprendre, utiliser ou présenter la V0.2.

La V0.2 en bref

Question	Réponse
À quoi sert-elle ?	Comparer des estimations énergétiques de modèles pour explorer un routage plus sobre.
Quelles données ?	CompareAI comme référence estimée; ML.ENERGY et SweetSpot comme sources de mesures GPU distinctes.
Que prédit-elle ?	La longueur probable de la réponse, puis une énergie estimée en Wh par requête.
Que fait la V0.2 ?	Elle ajuste une énergie additive ou une loi de puissance selon les tokens d’entrée et de sortie.
Que ne fait-elle pas ?	Elle ne génère pas de réponse, ne contacte aucun LLM et ne mesure pas directement le GPU.

1. Parcours d’une requête

Étape	Calcul	Résultat
1. Lire le prompt	Compter ses caractères; approximer caractères / 4.	Longueur d’entrée estimée en tokens.
2. Prévoir la réponse	Utiliser l’historique de réponses dans une tranche de longueur d’entrée.	Longueur de sortie estimée, par modèle si les données suffisent.
3. Estimer l’énergie	Appliquer au modèle un facteur ou une régression apprise sur les données de calibration.	Énergie estimée en Wh par requête.
4. Classer	Trier les modèles par énergie croissante; appliquer éventuellement un filtre historique de qualité.	Une liste de candidats, pas une réponse générée.

À garder en tête

Le classement dit quel modèle a la plus faible énergie prédite selon la calibration choisie. Il ne prouve ni que la réponse sera de qualité, ni que l’énergie du fournisseur sera égale à l’estimation.

2. Données et protocole d’évaluation

Source	Rôle dans le projet	Portée et précautions
CompareAI	Réponses, longueurs et référence énergétique utilisée pour calibrer puis comparer les estimations.	Référence estimée par la source; ce n’est pas une mesure indépendante de la consommation GPU.
ML.ENERGY Benchmark v3	Mesures GPU agrégées en facteur par token de sortie; 11 noms de modèles sont reliés à CompareAI.	202 configurations stables liées, mais GPU, nombre de GPU et batchs hétérogènes.
SweetSpot	Validation indépendante de lois entrée/sortie sur des mesures contrôlées.	13 modèles mesurés sur NVIDIA H100 avec TensorRT-LLM; les résultats sont propres à cette plateforme.

L’évaluation CompareAI ne garde que les conversations à un tour avec une paire de modèles, une longueur de sortie positive et une référence énergétique disponible. Environ 580 000 réponses valides sont exploitées; 113 modèles disposent d’un facteur direct et un modèle supplémentaire utilise un facteur de repli estimé à partir de la taille du modèle.

Les deux réponses d’une même paire restent ensemble dans le même sous-ensemble. Un hash de l’identifiant de paire crée un split déterministe d’environ 80 % pour la calibration et 20 % pour le test. Les observations du test ne servent donc pas à ajuster les paramètres évalués.

Pourquoi ce split compte

Si les deux réponses d’une même question se retrouvaient de part et d’autre du split, le test pourrait profiter d’informations très proches déjà vues à l’entraînement. Le split par paire limite cette fuite.

3. Les formules expliquées

3.1 Estimer les tokens du prompt

```
T_in estimé = max(1, plafond(nombre de caractères / 4))
```

C’est une approximation rapide. Le nombre réel de tokens dépend du tokenizer, de la langue et du modèle. La règle ne lit pas la sémantique du prompt.

3.2 Estimer les tokens de réponse

```
T_out estimé(m) = médiane des sorties observées pour le modèle m et la tranche d’entrée
```

Les sorties historiques sont regroupées dans quatre tranches d’entrée. Si le couple modèle × tranche a moins de 100 observations de calibration, le calcul reprend la médiane de la tranche tous modèles confondus; si elle manque, il reprend la médiane globale.

Tranche	Tokens d’entrée
1	1 à 31
2	32 à 127
3	128 à 511
4	512 et plus

3.3 Calibrer le facteur énergétique CompareAI

```
f_m = somme(énergie de référence en kWh) / somme(tokens de sortie)
```

Le facteur est estimé séparément pour chaque modèle sur la calibration. Quand un modèle a au moins 100 réponses utilisables, le facteur direct est retenu. Sinon, le prototype estime un facteur de repli avec une régression log-log qui utilise le nombre total de paramètres du modèle.

3.4 Référence V0.1 sortie seule

```
E_hat_m (Wh) = 1 000 × f_m (kWh/token) × T_out estimé(m)
```

La V0.1 transforme la longueur de sortie prédite en énergie. Elle ne modélise pas séparément un coût d'entrée. Le facteur énergétique reste celui appris à partir de la référence CompareAI.

3.5 V0.2 additive entrée et sortie

```
E_hat_m (Wh) = 1 000 × [b0_m + b_in_m × T_in + b_out_m × T_out]
```

b0 représente une base par requête; b_in et b_out sont les coûts estimés par token d'entrée et de sortie. Les coefficients sont ajustés par modèle sur les paires de calibration et sont contraints à être positifs ou nuls. Si un modèle a trop peu d'observations, il revient au calcul sortie seule.

3.6 V0.2 loi de puissance entrée et sortie

```
E_hat_m (Wh) = 1 000 × B_m × (1 + T_in)^a_m × (1 + T_out)^b_m
```

B est une base énergétique en kWh par requête. Les exposants a et b indiquent comment l'énergie varie avec la longueur d'entrée et la longueur de sortie. Ils sont ajustés par modèle; les deux exposants sont contraints à être positifs ou nuls. Le terme 1 + longueur permet d'ajuster la formule avec log(1 + tokens). En cas de données insuffisantes, le calcul retombe sur la sortie seule.

Ce que signifie un coefficient d'entrée nul

Dans cette calibration CompareAI, la régression n'a pas détecté de contribution d'entrée supplémentaire. Cela décrit le signal appris dans cette référence et cette période; ce n'est pas une preuve que traiter des tokens d'entrée ne consomme aucune énergie physique.

3.7 Variante ML.ENERGY

```
f_ML (kWh/token) = médiane des mesures (J/token) / 3 600 000
```

Le facteur ML.ENERGY est calculé à partir des configurations GPU stables reliées. Dans cette version, il s'applique à la sortie; aucun terme d'énergie d'entrée appris dans CompareAI n'est ajouté à cette source. Une mesure GPU de configuration n'est pas interchangeable avec l'énergie d'une API commerciale.

4. Comment lire les indicateurs

Indicateur	Ce qu'il mesure	Sens souhaitable
MAE énergie (Wh)	Moyenne des écarts absolus entre énergie prédite et référence.	Plus faible.
Erreur relative médiane	Erreur en pourcentage pour une observation typique; la médiane réduit l'effet des cas extrêmes.	Plus faible.
Ratio médian prédiction / référence	Niveau de prédiction global : proche de 1 signifie peu de biais médian; sous 1 indique une sous-estimation.	Proche de 1.
Exactitude de routage	Part des paires où le modèle prédit moins énergivore est aussi le moins énergivore dans la référence.	Plus élevée.

Indicateur	Ce qu'il mesure	Sens souhaitable
MAE sortie estimée	Écart moyen entre le nombre prédit et le nombre observé de tokens de réponse.	Plus faible.
Couverture qualité	Part des cas où au moins un modèle passe le seuil de qualité historique.	À arbitrer avec la qualité et l'énergie; couverture plus élevée n'est pas toujours meilleure.

Une différence entre deux pourcentages se lit en points de pourcentage. L'exactitude de routage évalue le choix énergétique sur des paires, pas la qualité du texte produit. La MAE et l'erreur relative évaluent la proximité avec la référence CompareAI, pas la précision d'un wattmètre.

5. Résultats et interprétation

5.1 Comparaison des variantes énergétiques

Variante évaluée	MAE énergie (Wh)	Erreur relative médiane	Exactitude routage
V0 globale CompareAI	3,0468	84,6 %	87,0 %
V0 par longueur d'entrée	1,2130	51,9 %	87,0 %
V0.1 modèle × longueur	1,0084	38,9 %	90,6 %
V0.2 additive entrée + sortie	1,0084	38,9 %	90,6 %
V0.2 puissance entrée + sortie	1,0084	38,9 %	90,6 %

La personnalisation de la longueur de sortie par modèle et tranche d'entrée (V0.1) améliore la reproduction de la référence par rapport à la V0 par longueur : la MAE passe de 1,2130 à 1,0084 Wh, soit environ 17 % de moins; l'erreur relative médiane baisse de 51,9 % à 38,9 %, et l'exactitude de routage monte de 87,0 % à 90,6 %. La MAE sur la longueur de sortie passe aussi de 497,9 à 412,7 tokens.

Les deux régressions V0.2 sont à égalité avec V0.1 sur ces trois indicateurs du test. Leur exposant d'entrée médian positif et leur contribution médiane d'entrée estimée valent zéro. Conclusion : l'ajout des termes entrée/sortie est une évolution méthodologique intéressante, mais aucun gain n'est démontré sur ce hold-out CompareAI.

5.2 Résultats du filtre qualité

Filtre	Modèles éligibles	Couverture	Résultat de qualité	Résultat énergétique
Votes utilisateurs	23	42,5 %	Accord après filtre : 63,7 %	79,3 % des choix filtrés moins énergivores; écart moyen vs vote : −0,0183 Wh.
Réactions	49	67,9 % de 3 455 paires	Score moyen : 0,654; le modèle routé égale/dépasse l'autre dans 78,3 % des cas.	Énergie routée − autre réponse : −0,6092 Wh en moyenne.

Dans le filtre de votes, un écart moyen négatif signifie que le routage retient un modèle un peu plus énergivore que le choix des utilisateurs, selon la référence CompareAI; ce filtre ne garantit donc pas une économie. Pour le filtre par réactions, l'écart est calculé comme énergie routée moins énergie de l'autre réponse : le signe négatif indique ici une énergie plus faible pour le modèle routé. Les deux filtres couvrent des sous-ensembles différents; leurs résultats ne s'additionnent pas.

Proxy de qualité, pas garantie

Les votes expriment des préférences historiques et les réactions sont des évaluations partielles et subjectives. Leur seuil influence le nombre de modèles admissibles et les cas couverts. Ils ne prédisent pas avec certitude la qualité d'une réponse future.

5.3 Comparaison hybride ML.ENERGY

Variante par longueur	MAE	Erreur relative médiane	Exactitude routage
CompareAI (référence estimée)	1,2130 Wh	51,9 %	87,0 %
Hybride : facteurs ML.ENERGY pour 11 modèles	1,2310 Wh	57,5 %	86,2 %

Dans cette comparaison V0 par longueur, le remplacement des facteurs des 11 modèles reliés par les médianes ML.ENERGY ne réduit pas l'erreur face à CompareAI. Cela ne signifie pas que ML.ENERGY est une mauvaise source : elle mesure une autre cible, sur des GPU et charges variés. Les métriques ci-dessus jugent sa capacité à reproduire CompareAI, pas sa fidélité à la consommation électrique réelle des fournisseurs.

5.4 Vérification indépendante sur SweetSpot

SweetSpot fournit des mesures sur H100 avec TensorRT-LLM. Trois rapprochements de versions ont été retenus; pour chaque modèle, 35 configurations servent à la calibration et 14 au test. La loi de puissance réduit l'erreur relative médiane dans les trois cas, mais augmente la MAE absolue : les deux critères donnent donc des lectures différentes.

Modèle SweetSpot	Erreur relative médiane base + sortie	Erreur relative médiane puissance	MAE base + sortie (J)	MAE puissance (J)
Llama 3.1 8B Instruct	48,6 %	32,5 %	58,4	70,1
Gemma 2 9B IT	62,7 %	32,6 %	156,2	195,4
Qwen2 7B	50,6 %	34,4 %	32,7	37,0

Ce test indépendant montre qu'une relation entrée/sortie peut être utile pour décrire les mesures H100, sans démontrer qu'elle généralise aux API cloud. Les rapprochements incluent des versions proches, pas toujours strictement identiques. Pour Llama 3.1 8B, le transfert du facteur CompareAI donne une prédiction médiane d'environ 3,07 fois la mesure SweetSpot sur 49 configurations; le classement de ces configurations reste néanmoins corrélé (0,841). Ce résultat illustre surtout que les sources et environnements ne sont pas interchangeables.

6. Utiliser le prototype

6.1 Lancer l'application complète en local

L'application complète a besoin de données CompareAI accessibles localement. Dans le dossier de partage, le fichier conversations.parquet est requis pour calculer l'estimation; reactions.parquet active le filtre par réactions; votes.parquet est requis pour l'évaluation des votes. Ces données ne sont pas incluses dans le paquet collaborateur et doivent provenir d'une source autorisée.

```
source_données\compareAI\conversations.parquet
source_données\compareAI\reactions.parquet
source_données\compareAI\votes.parquet
```

Noms et emplacements attendus à partir de la racine du projet.

Depuis PowerShell, dans le dossier extrait du paquet V0.2 :

```
& '.\.venv\Scripts\python.exe' -m streamlit run '.\interface_web_v01.py' --server.address 127.0.0.1
& '.\.venv\Scripts\python.exe' '.\estimateur_v0.py' --eval
```

6.2 Lire l’onglet d’évaluation

1. Sélectionner la source énergétique (CompareAI ou ML.ENERGY) et la variante (V0.1 sortie seule, V0.2 additive ou V0.2 puissance).
2. Régler si besoin les seuils de votes ou de réactions dans la barre latérale.
3. Dans l’onglet d’évaluation, lancer le calcul. Le résumé compare V0.2 à V0.1 et indique la direction des métriques; la sortie détaillée reste disponible dans un panneau repliable.
4. Interpréter les erreurs comme des écarts à la référence disponible, puis vérifier couverture, source et limites avant de conclure.

6.3 Démo web autonome

La démo publique prévue est un périmètre distinct : elle utilise SweetSpot/H100, demande directement la longueur d’entrée et la longueur de réponse visée, et classe 13 modèles par énergie estimée. Elle ne prend pas le texte du prompt, ne génère pas de réponse et n’applique pas le filtre qualité. Elle permet de tester le calcul sans télécharger le code, mais ne remplace pas l’application locale qui évalue CompareAI.

7. Limites et prochaines améliorations

- La règle caractères / 4 estime les tokens; il faudrait utiliser le tokenizer réel de chaque modèle pour les prompts connus.
- La longueur de réponse est une prédiction historique par tranche; elle n’est pas la sortie réelle d’un modèle sur la requête saisie.
- CompareAI est une référence estimée. Une mesure contrôlée de puissance ou d’énergie GPU est nécessaire pour valider des Wh physiques par requête.
- Les résultats SweetSpot proviennent d’un H100/TensorRT-LLM et de petits tests par version rapprochée; ils ne décrivent pas les API des fournisseurs.
- Le score de qualité est un proxy historique, sensible aux seuils, aux populations et à la subjectivité des retours.
- Le prototype ne modélise pas la latence, le coût financier, la tâche, la précision de réponse ni l’empreinte du cycle de vie du matériel.

Pistes pour la V0.3

5. Mesurer directement l’énergie sur une plateforme contrôlée, en faisant varier séparément tokens d’entrée, tokens de sortie, batch et modèle.
6. Répéter les configurations et fournir des intervalles d’incertitude plutôt qu’un seul chiffre moyen.
7. Évaluer par catégories de tâches et intégrer la latence avec l’énergie et les indicateurs de qualité.
8. Définir un jeu de test de qualité indépendant et quantifier le compromis entre couverture, qualité, énergie et taux de refus.
9. Comparer les modèles uniquement dans des conditions d’inférence documentées et afficher les cas hors de la plage calibrée.

8. Glossaire

Terme	Définition simple
Calibration	Ajustement des facteurs et coefficients à partir des données d’entraînement.
Hold-out	Partie des données mise de côté pour mesurer les performances sans l’utiliser pour ajuster les paramètres.
Token	Unité de texte utilisée par un modèle; elle ne correspond pas toujours à un mot.
MAE	Erreur absolue moyenne : écart moyen entre estimation et référence, dans la même unité.
Exactitude de routage	Fréquence à laquelle le classement choisit le modèle moins énergivore dans une paire.
Fallback	Méthode de repli utilisée quand un modèle ou une tranche a trop peu d’observations.
Wh / kWh / J	Wattheure, kilowattheure et joule : unités d’énergie; 1 Wh = 3 600 J.

Sources et provenance

- Méthodes, chiffres et règles de lancement : README_estimateur_v0.md et estimateur_v0.py du paquet V0.2.
- ML.ENERGY Benchmark v3 : https://huggingface.co/datasets/ml-energy/benchmark-v3. La fiche du jeu indique Apache-2.0 et des conditions d'accès à vérifier auprès de la source.
- SweetSpot LLM Inference Energy Efficiency Benchmark Dataset : https://doi.org/10.5281/zenodo.18714476 ; article : https://arxiv.org/abs/2602.05695. Licence déclarée dans le paquet : CC BY 4.0.
- CompareAI : copie locale autorisée du jeu de conversations; vérifier les conditions d'accès et de partage auprès du détenteur des données. La valeur énergétique est traitée ici comme une référence estimée.

Message de présentation en une phrase

La V0.2 teste si l'on peut mieux classer les modèles en estimant séparément l'effet des longueurs d'entrée et de sortie; pour l'instant, les données CompareAI ne montrent pas de gain par rapport à V0.1, et une validation physique reste à faire.