éco/routage

GUIDE D'UTILISATION · MODE D'EMPLOI

Prendre en main la plateforme.

Tout ce qu'il faut savoir pour estimer l'énergie d'un prompt, comparer les modèles de langage et choisir le plus sobre — en quelques minutes.

VERSION	PUBLIC	DURÉE DE LECTURE
V0.2 · PROTOTYPE	UTILISATEURS DE LA PLATEFORME	≈ 10 MINUTES

SOMMAIRE

Ce que contient ce guide

01	**Découvrir la plateforme**	À quoi elle sert, ce qu'elle ne fait pas
02	**Démarrer**	Lancer le moteur et ouvrir l'interface
03	**Se repérer dans l'écran**	Les deux colonnes et l'en-tête
04	**Lancer une estimation**	Prompt, source, méthode, filtre de qualité
05	**Lire les résultats**	Synthèse, compromis, classement
06	**Comparer deux modèles**	Le face-à-face et son enregistrement
07	**Historique et confidentialité**	Retrouver, conserver ou effacer ses analyses
08	**Exporter et documenter**	CSV et documentation intégrée
09	**Dépannage**	Messages d'état et solutions
10	**Bonnes pratiques et glossaire**	Bien interpréter, vocabulaire clé

> EN 30 SECONDES
>
> Écrivez votre prompt dans le panneau vert à droite, cliquez sur **Lancer l'estimation**, puis lisez à gauche le **modèle conseillé** et son **énergie estimée** en Wh. Comparez ensuite deux modèles dans le **face-à-face** et retrouvez tout dans **Historique**.

01 · DÉCOUVRIR

À quoi sert Éco-routage ?

Éco-routage estime l'énergie qu'une requête consommerait selon le modèle de langage utilisé, puis classe les modèles du plus sobre au plus énergivore. L'objectif : orienter chaque prompt vers un modèle adapté et économe.

ENTRÉE

Votre prompt

Le texte que vous enverriez à une IA, jusqu'à 4 000 caractères.

CALCUL

Une estimation

Tokens d'entrée, longueur de réponse prédite, énergie par modèle.

SORTIE

Un classement

Le modèle conseillé, son énergie en Wh et les alternatives.

Ce que la plateforme ne fait pas

- **Elle ne génère aucune réponse.** Aucun modèle d'IA n'est interrogé ; aucune API externe n'est appelée.
- **Elle ne mesure pas l'énergie en direct.** Les chiffres sont des estimations issues de données historiques (CompareAI) ou de mesures GPU de référence (ML.ENERGY).
- **Elle ne juge pas la qualité d'une future réponse.** Le filtre de qualité repose sur des réactions passées d'utilisateurs, pas sur une garantie.

CONFIDENTIALITÉ

Votre prompt reste dans votre environnement local. Il est transmis uniquement au moteur de calcul qui tourne sur votre machine.

02 · DÉMARRER

Lancer la plateforme

La plateforme se compose de deux éléments à démarrer : le **moteur de calcul** (API Python) et l'**interface** (application web). Dans le dossier `V0.2_partage` :

```
# 1. Moteur de calcul (terminal n°1)
python -m uvicorn api.main:app --reload --port 8000

# 2. Interface (terminal n°2)
cd frontend
npm run dev
```

Ouvrez ensuite `http://localhost:5173` dans votre navigateur. Sous le formulaire, le voyant doit afficher **« Moteur disponible — calcul sur données locales. »**

> PRÉREQUIS
> Les fichiers CompareAI (`conversations.parquet` et `reactions.parquet`) doivent être présents dans `source_données/compareAI/` . Sans eux, le calcul reste désactivé et la plateforme vous l'indique.

Arrêter la plateforme

Dans chacun des deux terminaux, appuyez sur `Ctrl` + `C`. Vos analyses en mode privé sont alors perdues ; celles conservées sur l'appareil restent disponibles au prochain lancement.

03 · SE REPÉRER

L'écran en un coup d'œil

L'interface est organisée en deux colonnes : à **droite**, vous posez la question ; à **gauche**, vous lisez la réponse du moteur.

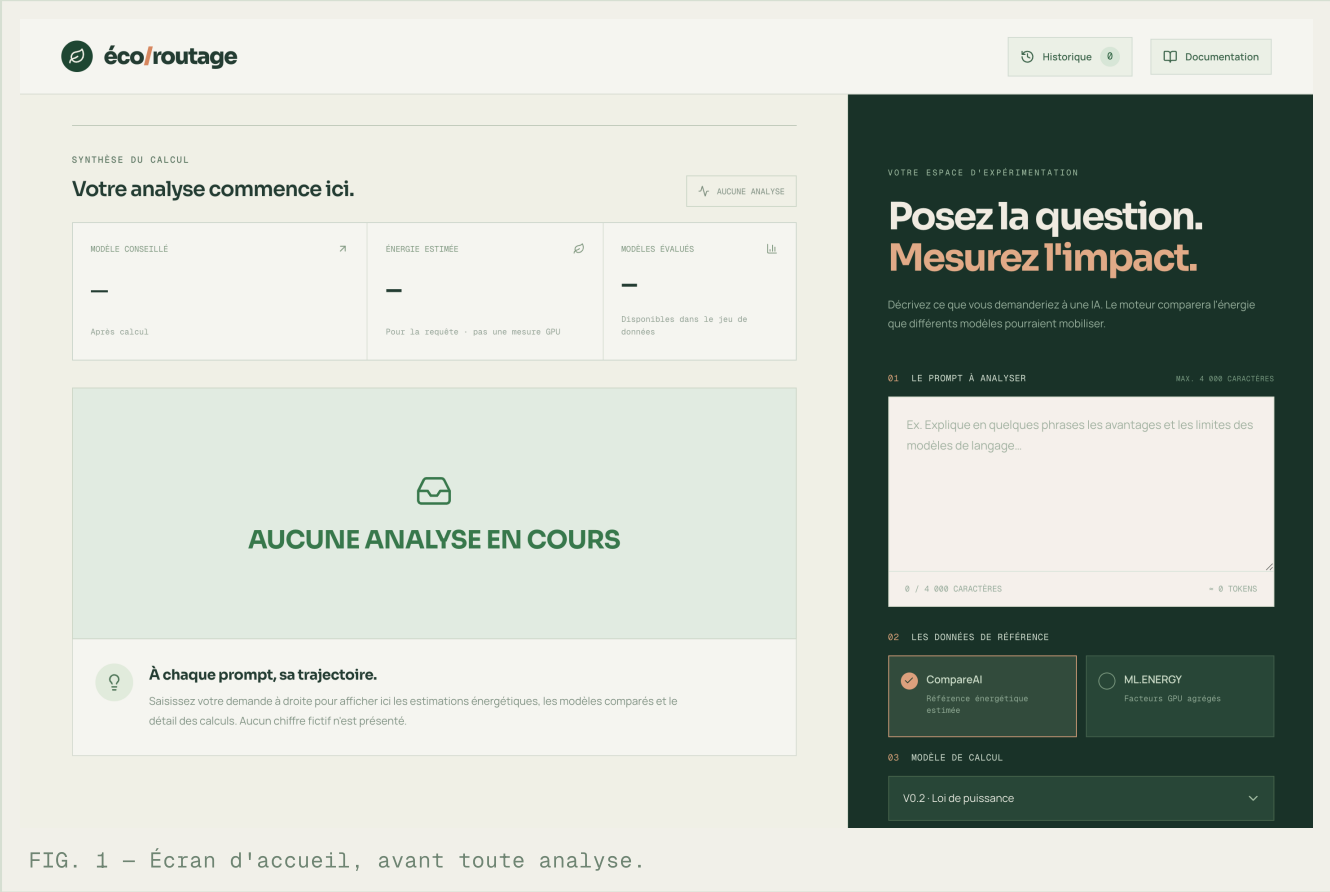


FIG. 1 — Écran d'accueil, avant toute analyse.

ZONE	RÔLE
En-tête	Logo (retour en haut de page), bouton **Historique** avec le nombre d'analyses, bouton **Documentation**.
Colonne gauche	Résultats : synthèse en trois cartes, compromis énergie / recommandation, classement complet et comparateur. Avant le premier calcul, elle affiche « Aucune analyse en cours ».
Colonne droite (verte)	Votre espace d'expérimentation : saisie du prompt, choix des données et de la méthode, filtre de qualité, bouton de lancement et état du moteur.

Sur un écran étroit (téléphone, fenêtre réduite), le formulaire passe au-dessus des résultats.

Lancer une estimation, pas à pas

01 **Saisir le prompt**
Rédigez la demande telle que vous l'enverriez à une IA. Le compteur indique le nombre de caractères (4 000 max.) et une approximation des tokens (≈ caractères ÷ 4).

02 **Choisir les données de référence**
CompareAI (par défaut) couvre tout le catalogue de modèles. **ML.ENERGY** s'appuie sur des mesures GPU, pour un nombre restreint de modèles.

03 **Choisir le modèle de calcul**
Laissez **V0.2 · Loi de puissance** si vous hésitez. Avec ML.ENERGY, la méthode « sortie seule » est imposée.

04 **Affiner le filtre de qualité** (optionnel)
Ouvrez la section pour ajuster les critères de recommandation (voir page suivante).

05 **Lancer l'estimation**
Le bouton devient actif dès que le moteur est disponible et que le prompt n'est pas vide. Pendant le calcul, **Annuler l'attente** permet d'interrompre.

> **PREMIER CALCUL**
> La première estimation peut prendre plus de temps : le moteur lit et calibre les données. Les suivantes sont plus rapides.

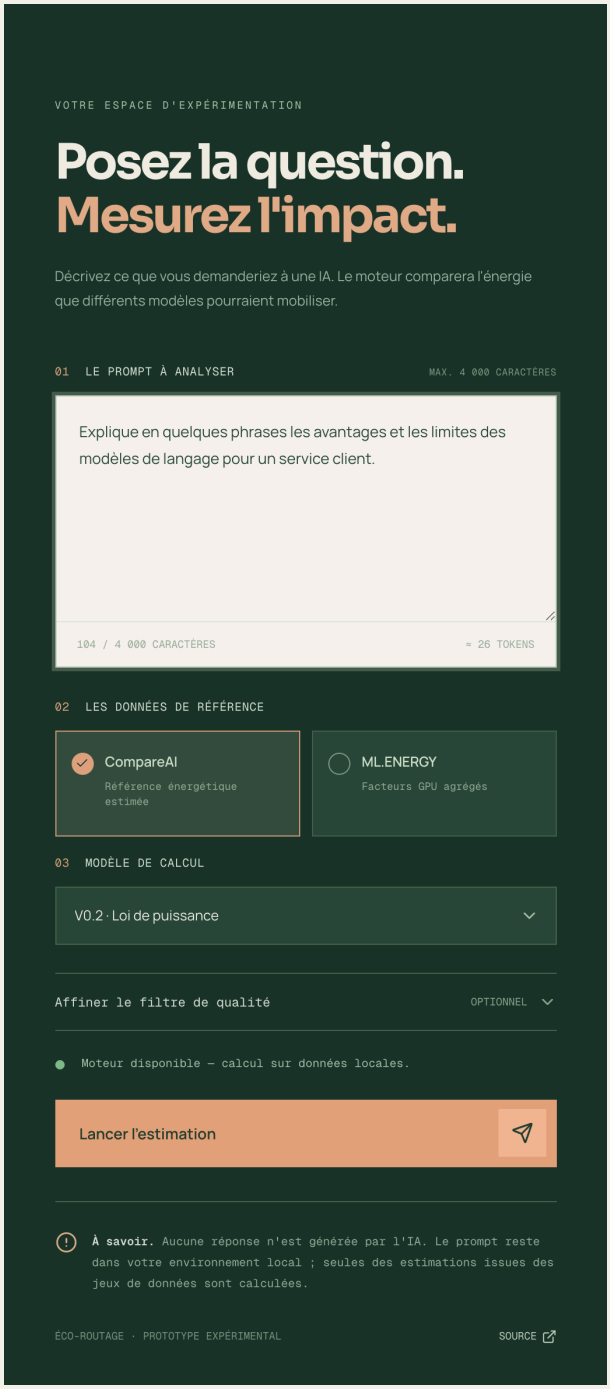


FIG. 2 — Le formulaire rempli.

Bien choisir ses réglages

Données de référence

SOURCE	CE QU'ELLE APPORTE	QUAND LA CHOISIR
CompareAI	Référence énergétique estimée à partir de l'historique de conversations ; couvre le plus grand nombre de modèles.	Par défaut, pour comparer largement.
ML.ENERGY	Facteurs issus de mesures GPU réelles (médiane de plusieurs configurations) ; affiche aussi la dispersion P10–P90.	Pour un point de vue « mesuré » sur les modèles couverts.

Modèle de calcul

MÉTHODE	PRINCIPE
V0.2 · Loi de puissance	Méthode par défaut. L'énergie dépend à la fois de la longueur du prompt et de la longueur de réponse prédite, de façon non linéaire.
V0.2 · Régression additive	Additionne une base par requête, une part liée à l'entrée et une part liée à la sortie. Le détail de chaque part est visible dans le classement.
V0.1 · Sortie seule	Version de référence : facteur énergétique × nombre de tokens de sortie estimés.

Filtre de qualité

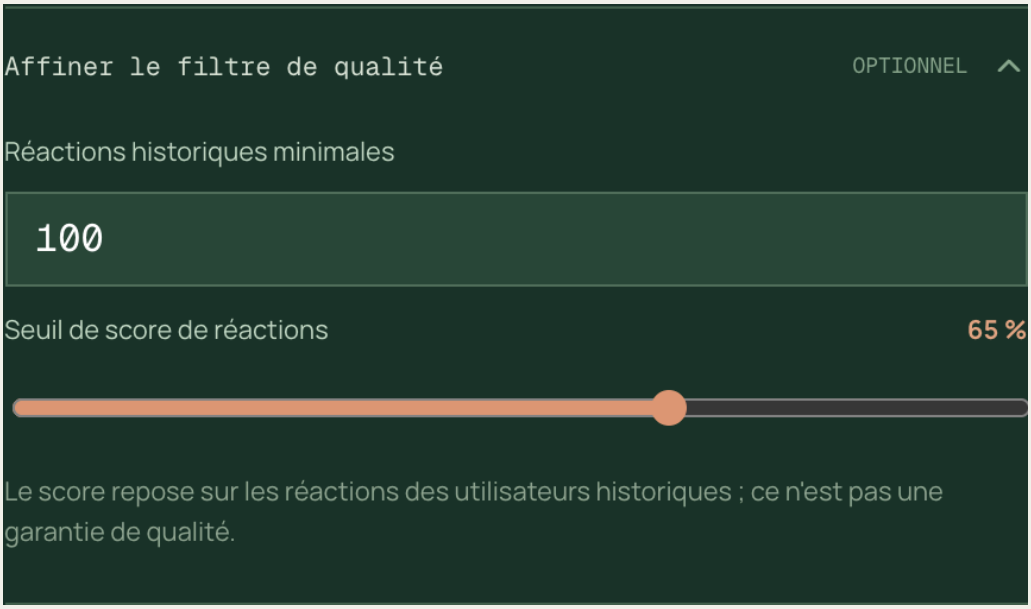


FIG. 3 — Section « Affiner le filtre de qualité ».

- **Réactions historiques minimales** (100 par défaut) : un modèle doit avoir reçu au moins ce nombre de réactions d'utilisateurs pour pouvoir être recommandé.
- **Seuil de score de réactions** (65 % par défaut) : part minimale de réactions positives exigée.

Plus le filtre est strict, plus la recommandation privilégie des modèles appréciés… quitte à s'éloigner du minimum énergétique. Le compromis est affiché clairement dans les résultats.

05 · LIRE LES RÉSULTATS

Comprendre ce que dit le moteur

La synthèse



FIG. 4 — Les trois cartes de synthèse.

- **Modèle conseillé** : le plus sobre parmi les modèles qui passent le filtre de qualité. La mention indique si le filtre a été appliqué.
- **Énergie estimée** : énergie de ce modèle pour votre requête, en wattheures (Wh). C'est une estimation, pas une mesure GPU.
- **Modèles évalués** : nombre total de modèles pris en compte dans le calcul.

Le compromis à connaître



FIG. 5 — Minimum énergétique (A) face à la recommandation (B).

Ce bloc confronte le **minimum énergétique absolu** (A) et le **modèle recommandé** (B). S'ils diffèrent, le surcoût est donné en Wh et en pourcentage : c'est le « prix » énergétique du filtre de qualité. S'ils coïncident, la recommandation est aussi la plus sobre.

Tous les chemins, un seul tableau

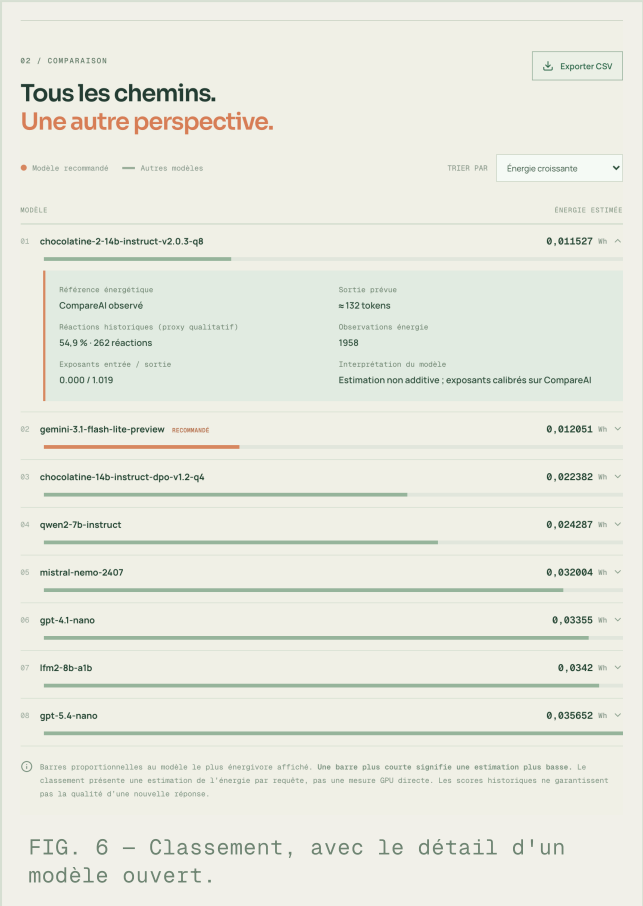


FIG. 6 — Classement, avec le détail d'un modèle ouvert.

Le classement liste les modèles les plus sobres du calcul, avec leur énergie estimée.

- **Barres** : proportionnelles au modèle le plus énergivore affiché. Une barre plus courte signifie une estimation plus basse.
- **Pastille orange « Recommandé »** : le modèle conseillé dans la synthèse.
- **Trier par** : énergie croissante, décroissante ou ordre alphabétique.
- **Cliquer sur une ligne** ouvre le détail : source du facteur énergétique, sortie prévue en tokens, réactions historiques, nombre d'observations, et selon la méthode, les exposants ou la ventilation base / entrée / sortie.
- **Exporter CSV** : télécharge le tableau (voir partie 08).

> **ASTUCE**
> Avec ML.ENERGY, le détail affiche la plage P10–P90 : elle reflète la variété des configurations GPU mesurées, pas un intervalle de confiance.

Le face-à-face entre deux modèles

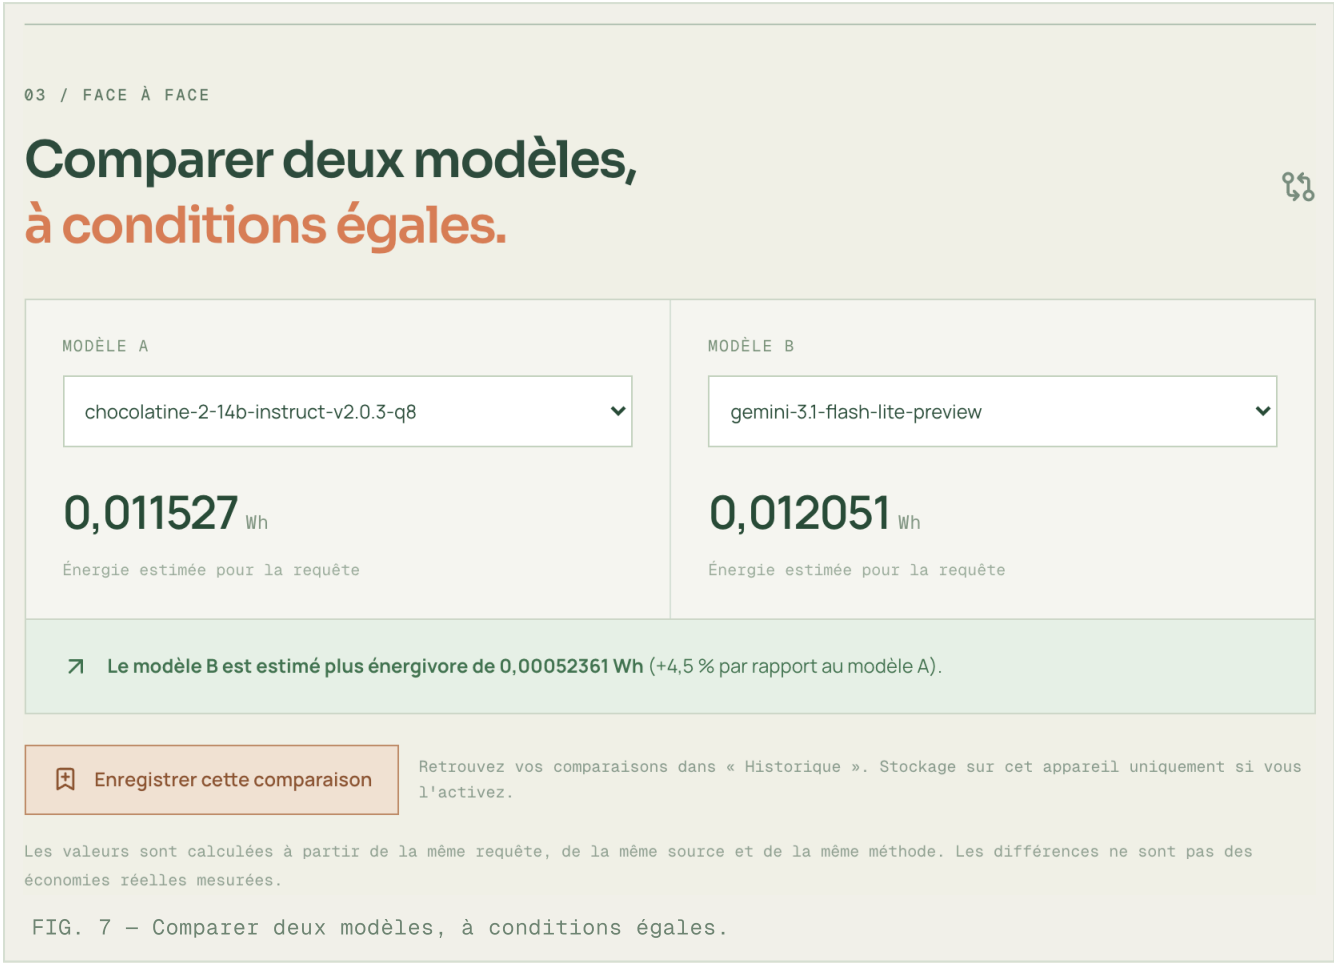


FIG. 7 — Comparer deux modèles, à conditions égales.

01 **Choisir le modèle A et le modèle B**

Par défaut, A est le minimum énergétique et B la recommandation. Changez-les librement via les listes.

02 **Lire la conclusion**

La bande verte indique de combien de Wh, et de quel pourcentage, le modèle B est plus ou moins énergivore que A.

03 **Enregistrer la comparaison**

Le bouton la rattache à l'analyse en cours. Vous la retrouverez dans l'Historique, prête à être rouverte.

Les deux valeurs reposent sur le même prompt, la même source et la même méthode : la comparaison est équitable. Les écarts restent des estimations, pas des économies mesurées.

07 · HISTORIQUE

Retrouver ses analyses

Le bouton **Historique** de l'en-tête ouvre un panneau latéral qui conserve jusqu'à **20 analyses**.

- **Revoir l'analyse** : réaffiche les résultats tels qu'ils étaient, sans relancer le moteur.
- **Comparaisons enregistrées** : un clic rouvre directement le face-à-face correspondant.
- **Corbeille** : supprime une analyse ; **Tout effacer** vide l'historique après confirmation.
- **Échap** ou la croix referment le panneau.

Confidentialité

MODE	COMPORTEMENT
Privé (par défaut)	Les analyses restent en mémoire jusqu'au rechargement ou à la fermeture de l'onglet. Rien n'est écrit dans le navigateur.
Conserver sur cet appareil	Les analyses sont enregistrées dans ce navigateur (localStorage), prompts compris, en clair. Décocher l'option efface cette copie.

> ATTENTION
>
> N'activez pas la conservation sur un ordinateur partagé si vos prompts sont sensibles. Rouvrir une analyse est une consultation : relancez l'estimation pour obtenir des valeurs à jour.

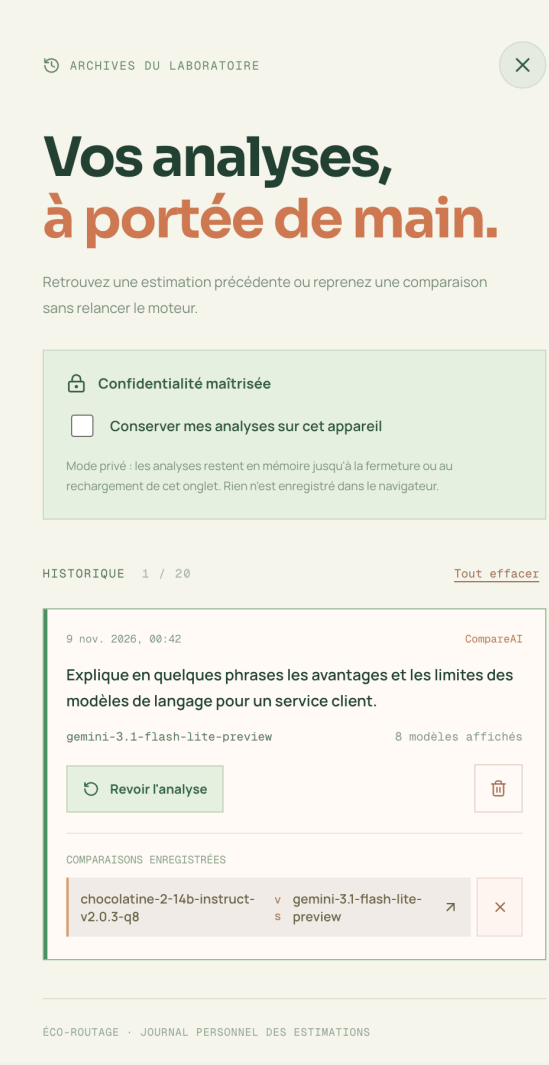


FIG. 8 — Le panneau Historique.

Partager et approfondir

Export CSV

Le bouton **Exporter CSV** du classement télécharge un fichier `eco-routage-resultats-AAAA-MM-JJ.csv`, lisible directement dans Excel (séparateur point-virgule, UTF-8). Chaque ligne correspond à un modèle affiché et reprend notamment :

- l'énergie estimée (Wh), les tokens de sortie estimés et le nombre d'observations ;
- le score et le nombre de réactions, et si le modèle est recommandé ;
- la source, la méthode, les tokens d'entrée approximés et le filtre appliqué ;
- selon la méthode, la ventilation base / entrée / sortie, les exposants ou la plage P10–P90.

Documentation intégrée

Le bouton **Documentation** ouvre une visionneuse avec deux documents : ce **guide d'utilisation** et la **documentation technique de la V0.2** (formules, résultats, limites). Chacun peut être ouvert dans un nouvel onglet ou téléchargé.

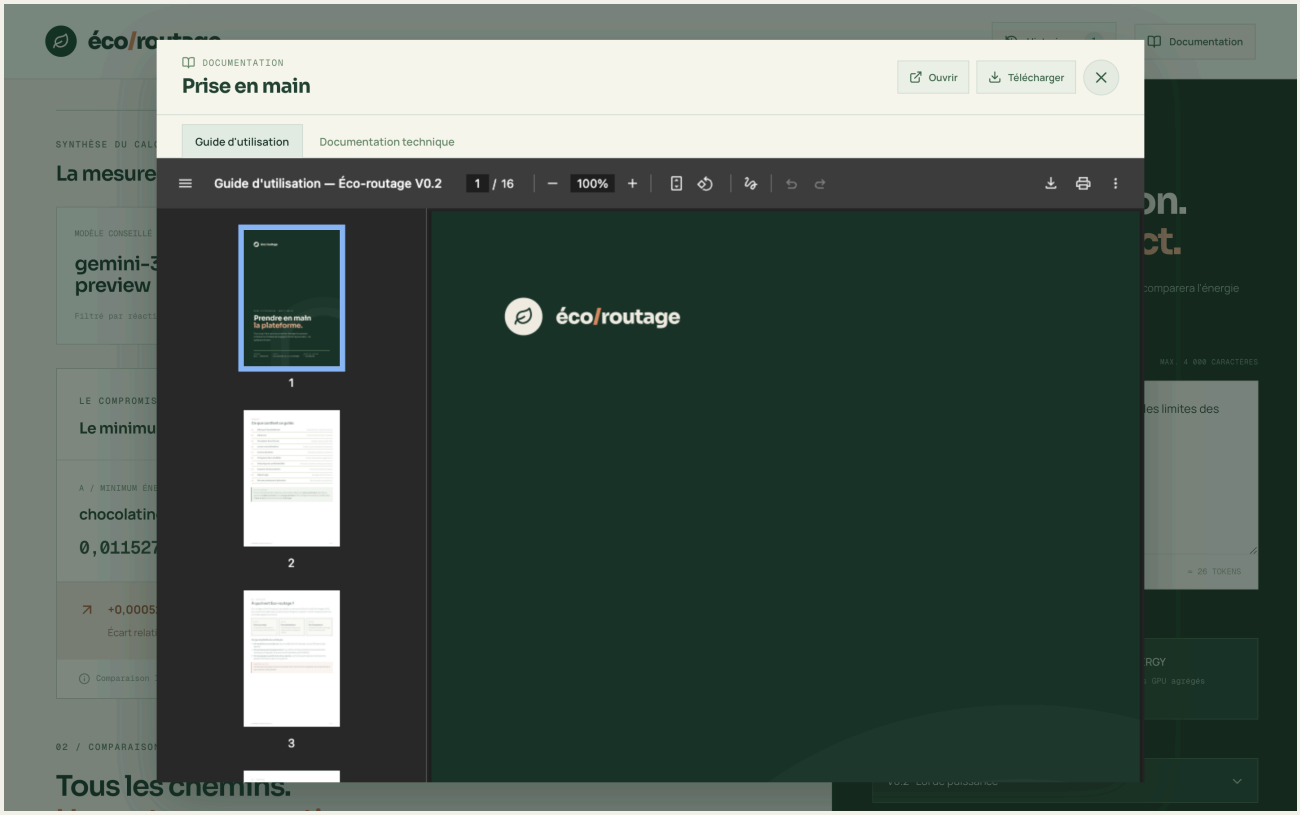


FIG. 9 — La visionneuse de documentation.

09 · DÉPANNAGE

Messages d'état et solutions

Le voyant situé sous le formulaire indique en permanence l'état du moteur. Voici comment réagir à chaque message.

MESSAGE AFFICHÉ	CAUSE PROBABLE	QUE FAIRE
Moteur disponible — calcul sur données locales.	Tout est prêt.	Saisissez un prompt et lancez l'estimation.
Connexion au moteur en cours…	L'interface interroge l'API.	Patientez quelques secondes.
API Python inaccessible.	Le moteur n'est pas démarré ou ne répond pas sur le port 8000.	Lancez `python -m uvicorn api.main:app --reload --port 8000`, puis cliquez sur l'icône de rafraîchissement à côté du message.
Jeu de données CompareAI manquant sur le serveur.	`conversations.parquet` est absent.	Placez-le dans `source_données/compareAI/`, puis rafraîchissez.
Fichier de réactions CompareAI manquant.	`reactions.parquet` est absent.	Ajoutez-le au même dossier.
Données ML.ENERGY manquantes.	Le fichier de mesures ML.ENERGY est absent.	Vérifiez `source_données/ml-energy-v3/runs/llm.parquet` ou revenez à CompareAI.

Autres situations

SITUATION	SOLUTION
Le bouton « Lancer l'estimation » reste grisé	Le prompt est vide ou le moteur n'est pas disponible : vérifiez le voyant.
Le calcul est long	Normal au premier lancement. Vous pouvez cliquer sur « Annuler l'attente » et relancer plus tard.
Un message d'erreur rouge apparaît	Le calcul n'a pas abouti : lisez le message, corrigez la cause (souvent le moteur) et relancez.
L'historique a disparu	En mode privé, il est effacé au rechargement. Activez « Conserver mes analyses sur cet appareil » pour le garder.
Le menu « Modèle de calcul » est bloqué	La source ML.ENERGY impose la méthode « sortie seule ». Revenez à CompareAI pour choisir une autre méthode.

Bien interpréter les résultats

- **Raisonner en ordre de grandeur.** Les valeurs en Wh servent à comparer les modèles entre eux pour une même requête, pas à facturer une consommation réelle.
- **Comparer à réglages égaux.** Ne comparez pas un résultat CompareAI avec un résultat ML.ENERGY : les sources reposent sur des bases différentes.
- **Tester plusieurs formulations.** La longueur du prompt influe sur la prédiction : essayez une version courte et une version détaillée.
- **Garder un œil sur le compromis.** Un filtre de qualité strict peut éloigner la recommandation du minimum énergétique.
- **Relancer plutôt que rouvrir.** Une analyse rouverte depuis l'historique est un instantané ; relancez pour actualiser.

Glossaire

Prompt	La demande écrite que l'on adresserait à un modèle d'IA.
Token	Unité de texte traitée par un modèle (≈ 4 caractères). L'énergie dépend des tokens d'entrée et de sortie.
Wh	Wattheure, unité d'énergie. Les estimations par requête sont souvent de l'ordre du centième de Wh.
CompareAI	Jeu de données de conversations et de réactions servant de référence énergétique estimée.
ML.ENERGY	Benchmark de mesures d'énergie sur GPU, utilisé comme source alternative pour les modèles couverts.
Loi de puissance	Méthode V0.2 qui relie l'énergie aux longueurs d'entrée et de sortie de façon non linéaire.
Filtre de qualité	Critères de réactions historiques (volume et score) qu'un modèle doit remplir pour être recommandé.
P10–P90	Plage couvrant 80 % des configurations GPU mesurées par ML.ENERGY.